


PROYECTO:

**LUGARES PARA COMER EN EL ESTADO DE LA FLORIDA,
ESTADOS UNIDOS**

Consultora de Data: UPDATA



Ornaldo Hernández Ramos
Cristian Ignacio Papini
Aaron Bernardo Martínez Vera
Jhoeliel David Palma Salazar
Janice Rocío Rico Sánchez

ÍNDICE

Introducción	03
Objetivos	04
Alcance	05
Metodología de Trabajo	08
Cronograma General - Diagrama de Gantt	09
Equipo de Trabajo – Roles y Responsabilidades	10
Diseño Detallado – Entregables	11
Datos Iniciales Suministrados	13
Proceso de Captación y Transformación de los Datos	14
Arquitectura de los Datos	15
Carga de Datos (Data Loads) en AWS Cloud	16
Diccionario de Datos	16
Proceso de ETL en Amazon Cloud	19
Dashboard	20
KPIs	21
Modelos de Machine Learning	22

INTRODUCCIÓN

Al estar en la era de la información y donde los datos más importantes y verídicos son los que provienen directamente de las personas, los reviews que se realizan a los lugares para comer a lo largo y ancho de los Estados Unidos arrojan puntos importantes a ser tomados en cuenta para conocer las preferencias de los clientes potenciales, así como información valiosa a la hora de aperturar nuevos locales.

Es por ello que se debe realizar un análisis de este mercado estadounidense, para apoyarse en la opinión de quienes tienen la experiencia de ir a estos lugares y degustar lo que ofrecen, sirviendo como ruta de conocimiento para quienes se disponen luego a hacer lo mismo.

El poder de las reseñas de los clientes deja un abanico de posibilidades a la hora de tomar decisiones no sólo para otros usuarios, sino también para los empresarios interesados en esta área comercial.

Google Maps ofrece gran cantidad de información acerca de restaurantes que detalla principalmente su localización, atributos y categorías. Asimismo se recogen las opiniones de los usuarios acerca de estos lugares, lo cual marca un hilo aprovechable para ser tomado en cuenta en posteriores soluciones.

OBJETIVOS

General:

- Proveer información veraz y puntual de lugares para comer en el Estado de la Florida, Estados Unidos, a comensales y empresarios, para que tomen decisiones más acertadas, cada uno en su área.

Específicos:

- Construir un Data Warehouse eficiente e integral, con data confiable, utilizando tanto los Datasets provistos por el cliente, como por otros adquiridos de forma externa por parte del equipo de Data Engineer.
- Analizar la opinión y calificación de los usuarios en Google Maps respecto a su interacción con los lugares para comer en el Estado.
- Analizar las locaciones de los restaurantes con mejores ratings.
- Dar recomendaciones a comensales y empresarios, tomando como base el resultado de los estudios previos.
- Presentar una herramienta web interactiva para usuarios que permita realizar diferentes consultas de lugares para comer.
- Conformar Dashboards con gráficas de análisis de datos, para que los empresarios identifiquen oportunidades de negocio en el ámbito de los restaurantes.
- Extraer y presentar KPIs para evaluar el desempeño de las herramientas generadoras de información.
- Entregar un informe de Machine Learning con Modelos adecuados que muestren predicciones que ayuden a la toma de decisiones para futuras inversiones.

ALCANCE

A través de este Proyecto se aplicarán procesos de EDA y ETL a los datos suministrados de sitios y reviews de usuarios de Google Maps, y se complementarán con otros obtenidos de diversas fuentes, logrando así una plataforma interactiva para que clientes puedan consultar opciones de lugares para comer en el Estado de Florida, Estados Unidos, de acuerdo a datos clave introducidos.

De igual forma se generarán dashboards informativos para empresarios interesados en invertir en la categoría de los lugares de comida, con cruce de datos que darán como resultado cifras y gráficos entendibles y valiosos para la toma de decisiones.

¿Por qué enfocarse en la Florida

- Según la Oficina de Censos de los Estados Unidos (United States Census Bureau), cuenta con una población de 21.538.187 habitantes (Censo del 01 de Abril de 2.020), de la cual más del 87% cuenta con una computadora y una suscripción a Internet, y 591.046 establecimientos que son fuente de empleo. Datos favorables para una buena opción de lugares para comer e invertir.

(<https://www.census.gov/quickfacts/fact/table/FL#>)

- Según la Oficina de Análisis Económico de Estados Unidos (The U.S. Bureau of Economic Analysis – BEA), el Cambio Porcentual de los Gastos de Consumo de Personas Reales allí está incluido en el rango de los más altos, de 10.4% a 12.5%.

(<https://www.bea.gov/data/consumer-spending/state>)

- Según la Asociación Nacional de Restaurantes (National Restaurant Association), hay alrededor de 40.000 establecimientos para comer y beber en la Florida, generando \$42 billones de ingresos. Algunas de las ciudades más famosas son Orlando, Miami, Tampa, West Palm Beach y Boca Raton.

(<https://restaurant.org/>) (<https://www.restohub.org/operations/planning/florida-restaurant/>)

- El 22 de Junio de 2022, en un artículo publicado por la página web de Forbes, Gilda D'Incerti, Fundadora y CEO de PQE Group, Compañía de Soluciones Tecnológicas y Servicios de Consultoría, y además Miembro del Consejo de Forbes, habló de “**3 Razones** del Porqué mi Compañía se está Mudando a Florida”. Es el 4to. Estado con mayor crecimiento económico (alrededor del 30% entre 2011 y 2021).

En 2019, Forbes clasificó a Florida en el 5to. lugar de su Lista de Mejores Estados para hacer negocios, detallando su alta tasa promedio de migración neta y proyectando que su crecimiento de empleo e ingresos superaría a la nación en los próximos cinco años. Florida también ocupa el primer lugar en el Índice de Emprendimiento en Etapa Inicial de Kauffman, con indicadores muy prometedores, como el 86% de los nuevos empresarios que crean un negocio allí por elección en lugar de necesidad, y una tasa de supervivencia de inicio del 80%.

1era. Razón: Gran Crecimiento en Empleos y Salarios. De acuerdo al censo de EE. UU., el crecimiento de la población de Florida durante la última década fue del 14,6%, el más alto de todos los estados. Florida también ha visto recientemente una afluencia de trabajadores remotos debido a su bajo costo de vida, y particularmente, el noreste parece ser un área popular para ello.

No es de extrañar que Florida sea tan atractiva para los trabajadores, ya que además de disfrutar de un bajo costo de vida, ganan más. Los salarios en el estado aumentaron un 9,7% de Diciembre de 2020 a Diciembre de 2021, el segundo mayor aumento en los EE. UU. A medida que más empresas abren oficinas en Florida, el mercado laboral en el Estado también está en auge. La tasa de desempleo bajó del 8,9% al 3% entre Abril de 2021 y Abril de 2022.

2da. Razón: Una Excelente Ubicación para Negocios. Florida se clasifica tan alto como un buen lugar para los negocios porque incluye políticas favorables para éstos y su entorno regulatorio es simplificado. El Estado ofrece incentivos para atraer todo tipo de empresas.

Allí también se encuentran 16 aeropuertos internacionales de servicio de pasajeros, y varios, como Tampa, Orlando y Miami, ofrecen vuelos directos a Europa. Además, hay varios nuevos desarrollos de transporte en proyecto, incluidos los sistemas ferroviarios.

Las políticas fiscales de Florida son otro atractivo. Es uno de los nueve estados sin impuesto sobre la renta, y no hay impuesto sobre herencias, donaciones o bienes muebles intangibles, como acciones. Además, las corporaciones tienen el beneficio de que solo deben pagar el 5.5% en su declaración de impuestos y no tienen impuestos sobre la nómina. Eso

puede cambiar las reglas del juego para un negocio que acaba de comenzar o para un negocio establecido que busca dejar un Estado con impuestos altos.

3era. Razón: El Estado del Sol. Es el estado más cálido de los EE. UU., con mucho sol y una temperatura anual promedio de 70.7 °F. El Estado más al sur de los EE. UU.; sus áreas norte y central tienen un clima subtropical y sus áreas del sur son tropicales. Su excelente clima durante todo el año hace que casi todos los días sean días de playa.

(<https://www.forbes.com/sites/forbesbusinesscouncil/2022/06/22/three-reasons-why-my-company-is-moving-to-florida/?sh=72fbe8175e9d>)

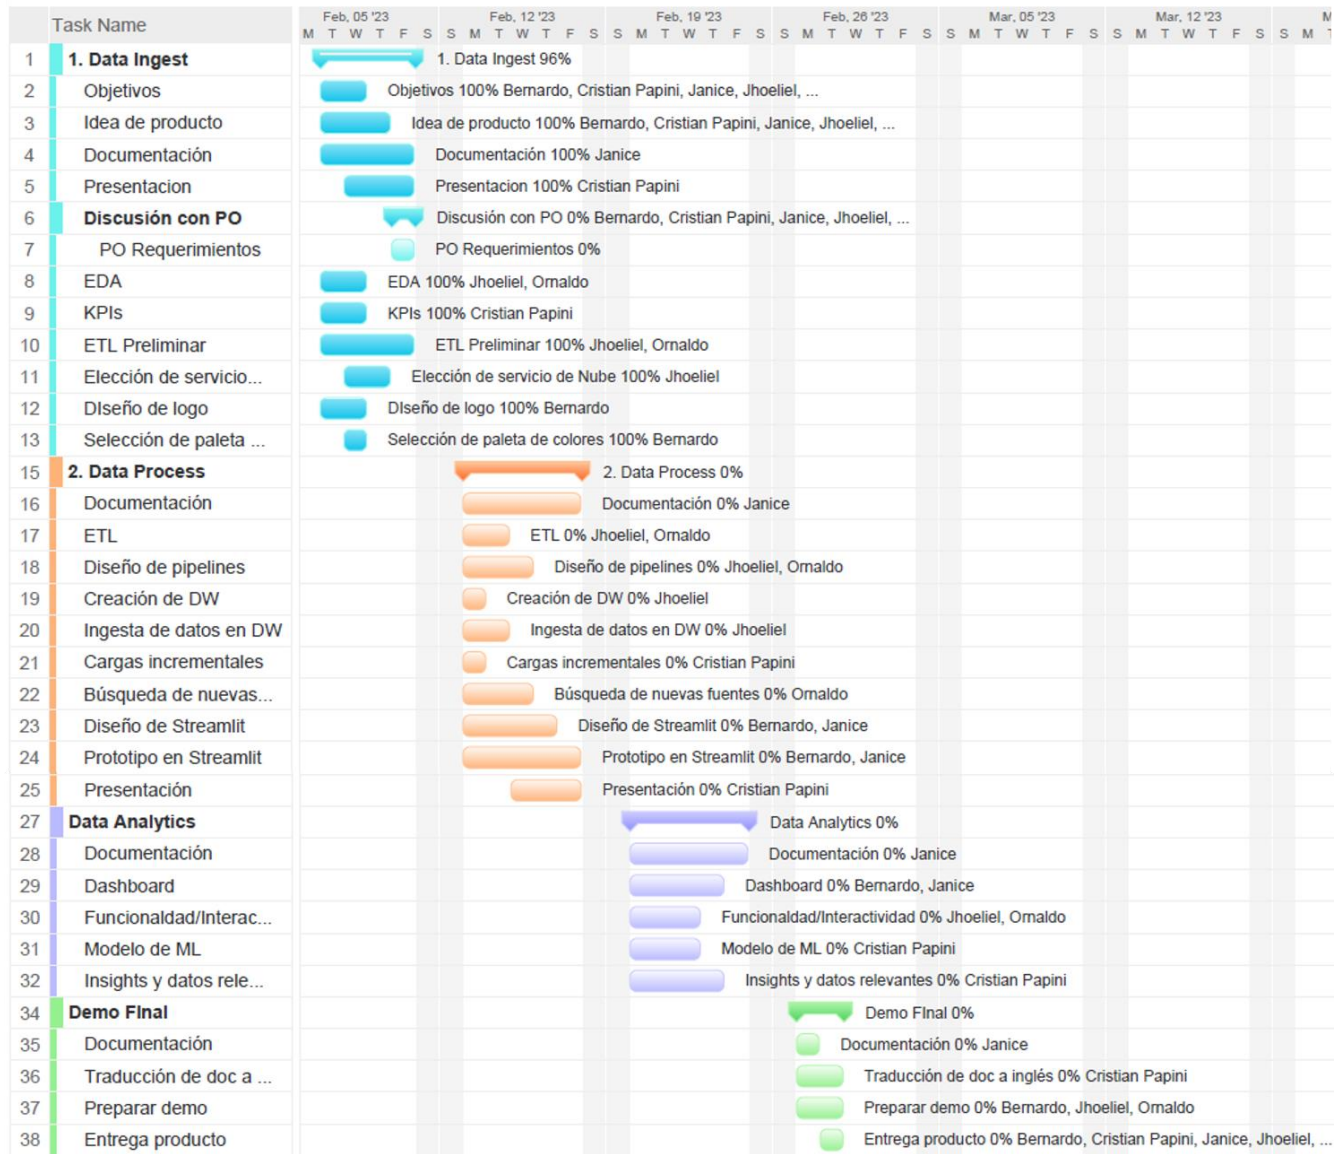
METODOLOGÍA DE TRABAJO

Para la ejecución de este Proyecto, desde los primeros pasos de análisis, hasta el producto final, se llevó a cabo una Metodología Ágil de tipo Scrum, con dailies del equipo de trabajo donde se discutieron los progresos del día anterior y las tareas para el actual.

Semanalmente se le reportaron al Product Owner los avances y metas logradas, así como recibir su retroalimentación.

Se establecieron metas para un mes (generales), por cada semana, y diarias. Para ello, se elaboró un Diagrama de Gantt, con el rol de cada miembro del equipo y los tiempos estimados para su ejecución.

CRONOGRAMA GENERAL - DIAGRAMA DE GANTT



EQUIPO DE TRABAJO – ROLES Y RESPONSABILIDADES

Los diferentes integrantes del equipos tuvieron diferentes roles de acuerdo a sus habilidades y decisión personal de trabajar en cierta área, lo que aumentó la eficiencia de las tareas que se realizaron durante la ejecución del mismo. Es así como cada uno reportó sus dudas y resultados a los demás miembros, de modo que se cumplieran los objetivos planteados y los deadlines exigidos.

El trabajo quedó repartido de la siguiente manera:

Data Engineer: Ornaldo Hernández.

Data Cloud Engineer: Jhoeliel Palma.

Data Analytics: Aaron Martínez y Janice Rico.

Machine Learning Engineer: Cristian Papini.

DISEÑO DETALLADO – ENTREGABLES

Cada uno de los archivos de trabajo y visualizaciones fueron almacenados en un Repositorio de GitHub (https://github.com/janicerico/PG_Google_Maps.git), el cual contiene:

- Jupyter Notebooks para los procesos de EDA, y ETL automatizado para la carga y tratamiento de los Datasets iniciales.
- Datasets finales a partir de los que se generaron la WebApp en Streamlit, los Dashboards y análisis con sus KPIs, y la aplicación de Modelos de Machine Learning.
- Plataforma interactiva para realizar las consultas referentes a Lugares para Comer recomendados para los comensales, así como Estadísticas extras para futuros Inversionistas.
- Dashboards con herramientas de AWS, incluyendo los KPIs generados, para los empresarios.
- Visualizaciones de los resultados de Modelos de Machine Learning.

DATOS INICIALES SUMINISTRADOS

Los Datasets suministrados están divididos en varias carpetas con la siguiente distribución:

Carpeta	Sub-Carpeta	Cantidad Archivos .json	Peso (Mb)
reviews-estados	review-Alabama	12	467,90
	review-Alaska	4	142,30
	review-Arizona	14	636,00
	review-Arkansas	16	611,80
	review-California	18	762,90
	review-Colorado	16	751,50
	review-Connecticut	18	673,60
	review-Delaware	7	235,00
	review-District_of_Columbia	4	160,90
	review-Florida	19	886,30
	review-Georgia	13	575,50
	review-Hawaii	11	471,70
	review-Idaho	14	569,50
	review-Illinois	14	587,50
	review-Indiana	15	599,00
	review-Iowa	18	673,00
	review-Kansas	13	511,00
	review-Kentucky	11	429,50
	review-Louisiana	10	385,30
	review-Maine	8	290,00
	review-Maryland	16	669,30
	review-Massachusetts	16	640,60
	review-Michigan	15	624,70
	review-Minnesota	12	502,80
	review-Mississippi	14	486,70
	review-Missouri	11	455,90
	review-Montana	7	248,00
	review-Nebraska	13	468,30
	review-Nevada	12	520,00
	review-New_Hampshire	9	342,40
	review-New_Jersey	13	539,80
	review-New_Mexico	12	486,90
	review-New_York	18	759,90
	review-North_Carolina	15	656,20
	review-North_Dakota	4	144,90
	review-Ohio	13	538,50
	review-Oklahoma	11	445,80
	review-Oregon	15	644,90
	review-Pennsylvania	16	658,30
	review-Rhode_Island	6	227,20
	review-South_Carolina	14	575,60
	review-South_Dakota	5	172,60
	review-Tennessee	12	497,40
	review-Texas	16	713,50

	review-Utah	10	477,20
	review-Vermont	3	85,60
	review-Virginia	12	480,80
	review-Washington	13	569,80
	review-West_Virginia	8	264,80
	review-Wisconsin	12	454,10
	review-Wyoming	3	111,00
		Total Peso (Mb)	24883,70
metadata-sitios		11	2832,30

PROCESO DE CAPTACIÓN Y TRANSFORMACIÓN DE LOS DATOS

A partir de toda la data y de la decisión de negocio de lugares para comer en el Estado de la Florida, Estados Unidos, se seleccionaron dos juegos de datos: El grupo de los 11 ficheros .json de “metadata-sitios” que contenían información de establecimientos en sentido general (respecto a utilidad y pertenencia geográfica), y otro grupo de 19 ficheros .json de “review-Florida” que contenían reseñas acerca de negocios.

La información acerca de los negocios (“metadata-sitios”) recibió diferentes transformaciones:

1. Se eliminaron los '\n' de las columnas de caracteres.
2. Después de analizar la tabla, se hicieron cambios en los tipos de datos de algunas columnas hacia otro tipo de datos que ocupara menos espacio y pudiera almacenar la misma información.
3. Se eliminó el tipo de dato de lista de cadenas a cadena en dos columnas.
4. Se salvaron los 11 ficheros .json en uno solo con un formato en .parquet, y otro en .csv.
5. Se eliminaron duplicados.
6. Se filtró la data por diferentes criterios: Que fueran RESTAURANT, BAKERY, DESSERTS, PASTRY, y de la Florida.
7. Se crearon nuevas columnas para el trabajo en Analytics y en Machine Learning; todo, a partir de la columna *address: st* (state) y *zip* (zip code). Se crearon otras columnas para marcar exactamente qué tipo de establecimiento era: Restaurant, Bakery, Desserts, Pastry.
8. Se crearon dos columnas: *open* y *close*, para indicar horarios de apertura y cierre del establecimiento; sólo cuando fue posible.
9. A partir de la columna *zip* se pudieron crear dos columnas nuevas: *county* (condado) y *city* (ciudad). Tomado de <http://census.gov>.

10. Se trató de obtener vía scraping, las coordenadas geográficas de cada uno de los establecimientos para mejorar las que venían en la data inicial, a partir de la columna *address*. El método encontrado funcionó bien, pero se basaba en el módulo Selenium que permite simular un navegador para renderizar el html generado por la url, y para obtener las coordenadas se demoró bastante. Esto había que hacerlo para más de 4.000 establecimientos, y después de tres días casi a tiempo completo, apenas se llegó a los 1.000. Luego se decidió seguir con las coordenadas que venían originalmente.

A partir de la tabla “review_FL” (tabla unificada de todos los reviews – 19 ficheros .json):

1. Se crearon dos nuevas columnas: *avg_rating* (promedio de los ratings de un establecimiento) y *num_of_reviews* (cantidad de reviews).
2. Se le agregaron cinco columnas: *rating1*, *rating2*, *rating3*, *rating4* y *rating5*, que tienen la suma de los ratings que coinciden con su nombre *rating1* = suma de los ratings = 1, y así sucesivamente.

Adicionalmente, se obtuvo información extra para que el equipo de Analytics y el de Machine Learning decidieran si tenía valor o no:

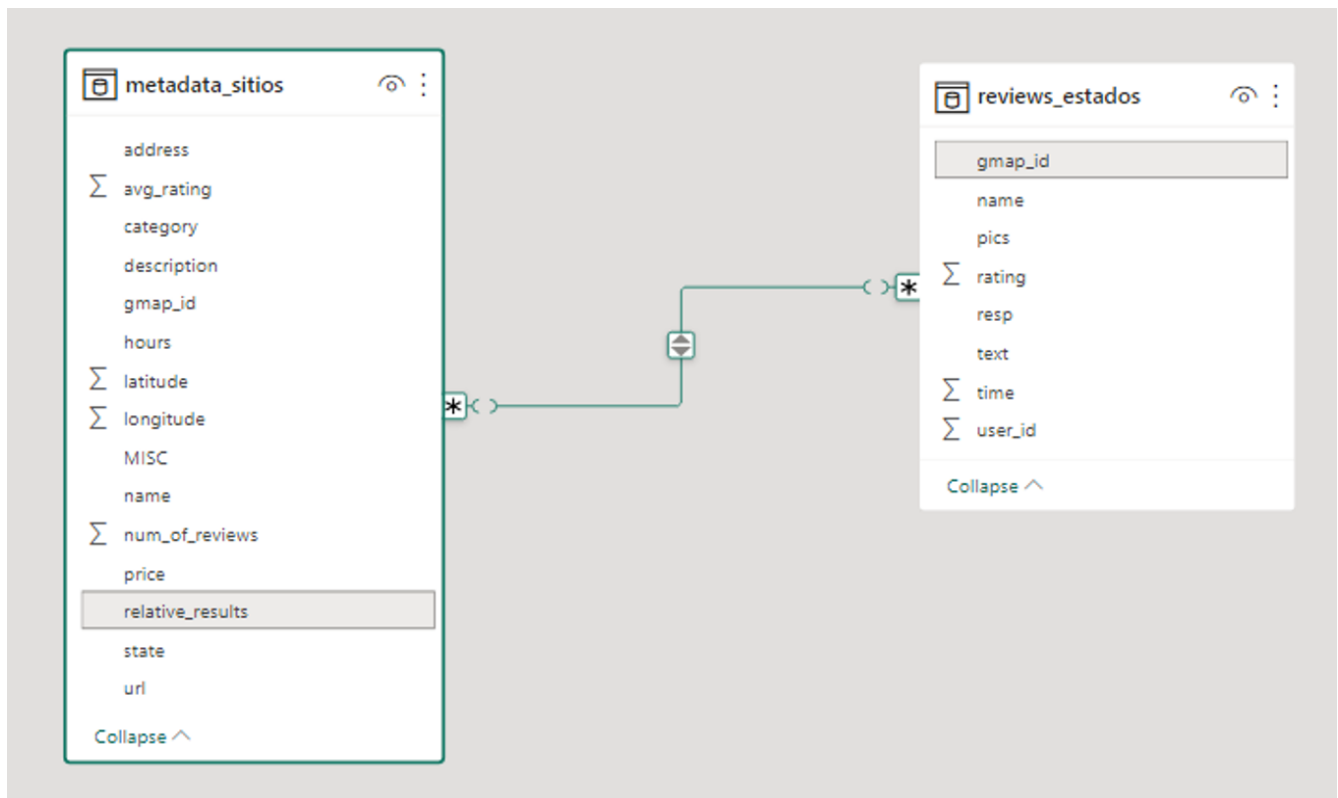
- *city_population*: Población de cada ciudad de la Florida.
- *Florida_population*: Saldo poblacional de la Florida, entre 1998 y 2020.
- *gdp*: Producto Interno Bruto de cada Estado de los Estados Unidos, entre los años 2021 y 2022.

(<http://census.gov>)


ARQUITECTURA DE LOS DATOS

Los datos en la capa RAW se encuentran en formato .json.

Los datos en las capas intermedias (stage) y los que estuvieron listos para consumo, están en formato .parquet, es decir, se trabajó con bases de datos columnares para aprovechar sus múltiples ventajas en entornos Big Data, como por ejemplo, la eficiencia de almacenamiento y la velocidad de acceso a datos. Esto es también posible debido a la estructura de las tablas proporcionadas que poseen pocas columnas, lo cual permitió NO trabajar con un modelo relacional estricto. Sin embargo, se pudieron reconocer algunas relaciones entre los datos provistos:



Además, los Datasets están presentados con una configuración tipo “view”, lo cual se pudo aprovechar con algunas transformaciones para su consumo posterior y llevarlo a una forma útil y consumible.



CARGAS DE DATOS (DATA LOADS) EN AWS CLOUD

Se gestionaron 2 tipos carga distintos debido a la naturaleza intrínseca de las tablas a usar:

Tabla dimensional: sitios_FI -> Contiene información acerca de los sitios (negocios del rubro culinario). No posee índices de tiempo. Para el mantenimiento / actualización se realizaron cargas totales con transformación posterior para la limpieza de datos.

Tabla referencial: florida_population_change -> Contiene información demográfica del Estado que fue usada para proporcionar un marco contextual a los análisis realizados. Aquí también se empleó el tipo de carga total con transformación posterior a la misma para la limpieza de datos.

Tabla de Hechos: review_FI -> Almacena información sobre registros de reseñas otorgadas a los locales. Dado que esta información sí tiene registro de tiempo se empleó cargas incrementales con un posterior tratamiento de limpieza de datos.

Así mismo hubo versiones especiales de algunas tablas que fueron usadas especialmente en los modelos de Machine Learning, Dashboard y la WebApp iTakeU.

DICCIONARIO DE DATOS

Tabla: sitios_FI_ML.csv (Usada en Modelo de Regresión Supervisado)

Columna	tipo	Descripción
Latitud	Float	Latitud
Longitud	Float	Longitud
avg_rating	Float	Rating
price	UInt8	Categoría del precio
cat_bakery-desserts	Bool	Categoría del Negocio
cat_bakery-rest	Bool	Categoría del Negocio
Cat_restaurant	Bool	Categoría del Negocio

Tabla: birth_dataset (Empleada en Amazon Forecast)

Columna	Tipo	Descripción
Time	Datetime	Fecha
State	String	Sigla del Estado
Births	Int	Cantidad de nacimientos

Tabla: death_dataset (Empleada en Amazon Forecast)

Columna	Tipo	Descripción
Time	Datetime	Fecha
State	String	Sigla del Estado
Deaths	Int	Cantidad de muertes

Tabla: int_migration_dataset (Empleada en Amazon Forecast)

Columna	Tipo	Descripción
Time	Datetime	Fecha
State	String	Sigla del Estado
Int_migrations	Int	Cantidad de migraciones internacionales

Tabla: local_migration_dataset (Empleada en Amazon Forecast)

Columna	Tipo	Descripción
Time	Datetime	Fecha
State	String	Sigla del Estado
Local_migrations	Int	Cantidad de migraciones locales

Tabla: sitios_FI (Empleada en Quicksight y StreamLit)

Columna	Tipo	Descripción
name	String	Nombre
address	String	Dirección
gmap_id	String	Id de Google maps
description	String	Descripción
latitude	Float	Latitud
longitude	Float	Longitud
category	String	Categoría del negocio
avg_rating	Float	Raiting promedio
num_of_reviews	int	Numero de reviews
price	String	Categoría de precio
MISC	Float	Misceláneos
state	String	Estado del negocio (activo o cerrado)
relative_results	String	Lista de Id de Google maps
url	String	url de mapa de local
street	String	Calle de la dirección
zip	int	Código postal
st	String	Estado de EEUU
City	String	Ciudad
horario	String	Horarios
open	String	Hora de apertura
close	String	Hora de Cierre
County Name	String	Nombre del condado

Tabla: city_population (Empleada en fase inicial de ETL para complementar transformaciones)

Columna	Tipo	Descripción
County_name	String	Nombre del condado
City	String	Ciudad
Poblacion	Float	Cantidad de habitantes

Tabla: reviews_FI (Empleada en Quicksight y StreamLit)

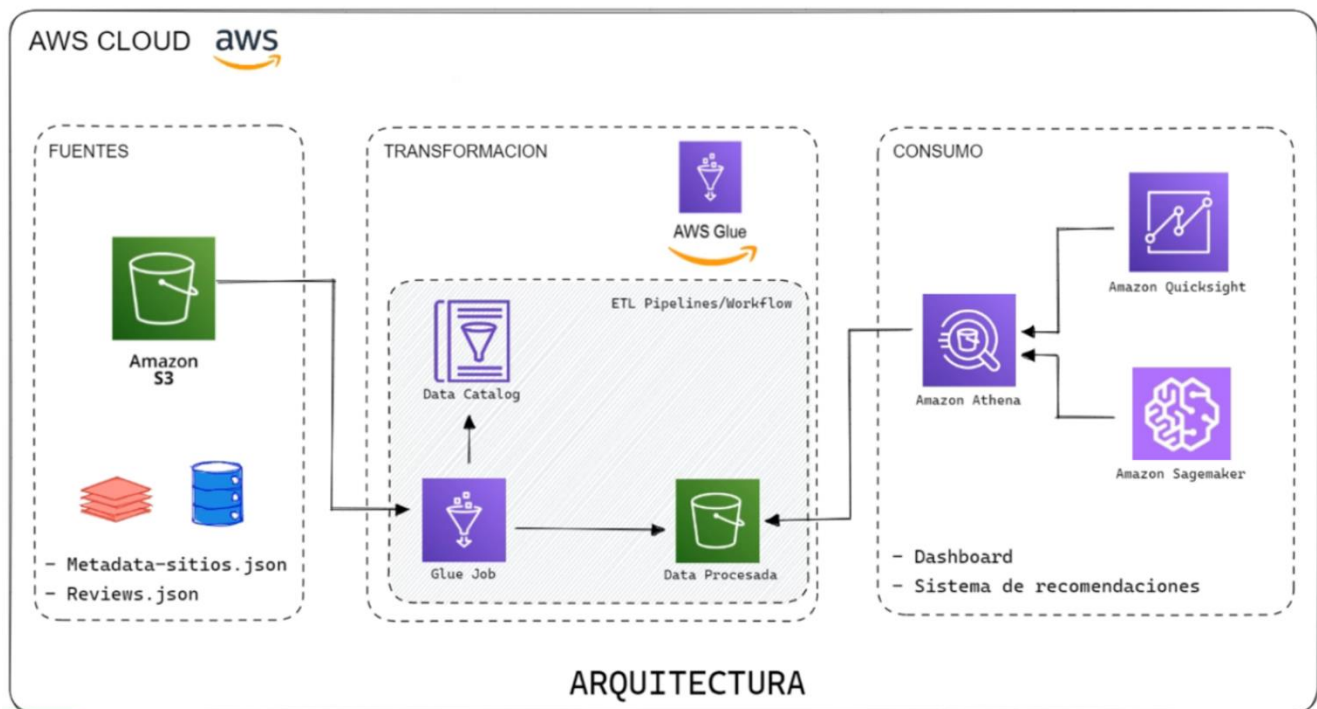
Columna	Tipo	Descripcion
name	String	Nombre del usuario
rating	float64	Rating otorgado
text	String	Texto de la review
date	Datetime	Fecha de review
zip	Int	Código postal

PROCESO DE ETL EN AMAZON CLOUD

Video Explicativo Proceso de ETL en Amazon AWS:
<https://www.youtube.com/watch?v=irX-6nPQTjI>

Video Mostrando el Proceso de Implementación del Proceso de ETL en AWS Cloud -
 Vista Rápida: <https://www.youtube.com/watch?v=3-nzZq9ZcF8>

DATA WAREHOUSE



DASHBOARD

Al inicio del desarrollo de este proyecto se planteó el uso de herramientas profesionales como AWS Cloud y sus servicios para facilitar la transformación de la información.

Primero se generó una investigación del funcionamiento de la extensión a utilizar (“Quicksight”). Luego se buscó información básica y dedicada a su correcta manipulación.

Por consiguiente, se obtuvo el Dataset dentro de los Buckets y se estudiaron (se familiarizó con las diferentes columnas y la información que mostraban). Finalmente se tomaron los campos con mayor relevancia para graficar, dependiendo de la información a visualizar y los KPI's desarrollados en las otras fases.

La herramienta que se usó fue “Quicksight”, la cual facilita la visualización de los datos en forma de gráfica y en un formato que consiste en seleccionar y arrastrar los campos deseados, y se ajustaron los elementos visuales con una paleta de colores amigable para el usuario y emblemática para la empresa.

KPIs

Para poder tomar decisiones e ir haciendo un seguimiento del comportamiento de las distintas variables existentes en el proyecto, se elaboraron KPIs, los cuales son métricas evaluadas en el tiempo que hacen énfasis en las variaciones.

A continuación los distintos KPIs propuestos y las preguntas y/o ideas a las cuales estos responden:

Count Reviews por Categoría:

Información: Cantidad de reseñas por categoría.

Preguntas a la que responde:

¿En qué categoría voy a tener más información sobre la cual apoyar mi decisión? Más información = Más capacidad de decisión.

¿En qué categoría es que tengo más apoyo/seguimiento por parte de los clientes? Mayor contacto con el cliente = Mayor capacidad de establecer lo que al cliente le gusta o no.

Rating por Categoría:

Información: Rating promedio por categoría.

Preguntas a la que responde:

¿Qué categoría tiene mejor reputación?

¿Qué categoría es la más aclamada por la gente? No quisiera apostar por categorías poco reconocidas por el público.

Count Reviews por Día:

Información: Cantidad de reseñas por día de la semana.

Preguntas a la que responde:

¿En qué días de la semana me conviene abrir el lugar?

¿Es conveniente tener abierto los 7 días de la semana? Más allá de que eso se define a través de un análisis económico-financiero, con la cantidad de reseñas se puede tener una idea de cómo es el flujo a lo largo de la semana.

Rating por Precio:

Información: Promedio de rating por tipo de precio.

Pregunta a la que responde:

¿Qué tipo de mercado es el más aclamado por la gente: Económico, intermedio o de alto nivel?

Esto me sirve para, más allá de las ideas que pueda tener acerca del negocio, adaptar mi idea a la demanda actual del mercado.

MODELOS DE MACHINE LEARNING

Teniendo en cuenta los Datasets con los que se contaban y la idea de negocio que se pretendía, se pensaron diferentes modelos de Machine Learning que le sirvieran al cliente para tomar decisiones a futuro.

Modelo de Predicción – Amazon Forecast

Para esto, primero se creó un Modelo de Predicción con la herramienta Amazon Forecast, en la cual se subieron los Datasets de Nacimientos, Muertes, Migraciones Internacionales y Locales, con información desde 1.990 a 2.020. Luego de crear predictores en la herramienta acorde a los datos que se tenían (en este caso la misma escoge el predictor que mejor se adapte al Dataset), se entrenó y se creó un pronóstico. Este último tuvo una capacidad de predecir hasta 7 años posteriores a la última fecha con la que se contó, en este caso 2.020, por ende, el pronóstico llegó hasta el año 2.027.

Como resultado, para cada una de las 4 variables mencionadas, se obtuvo una serie de datos con los cuales se construyó un gráfico y sus respectivos percentiles. Estos ayudaron en la comprensión y lectura del pronóstico.

Si al comportamiento poblacional del Estado, se le suma el análisis del GDP (Growth Domestic Product) y el PCE (Personal Consumption Expenditures), crecimiento y consumo respectivamente, se estaría en condiciones de predecir si el Estado de la Florida es una buena opción para inversionistas.

Modelo de Clasificación Supervisado – Amazon Sagemaker

Luego de analizar los pronósticos antes mencionados, se decidió que el Estado de la Florida es un buen lugar para realizar inversiones del tipo gastronómico. Se sabe que este rubro es demasiado amplio y es por eso que se decidió elaborar un modelo de Machine Learning que predijo, dada ciertas condiciones, el Rating estimado del lugar.

Para esto, se utilizó la herramienta Amazon Sagemaker para elaborar un Modelo de Machine Learning en el cual se aplicaron Random Forests con una precisión del 68%.

Los inputs que el usuario del modelo debe ingresar son:

- Coordenadas del lugar.
- Tipo de precio (0,1,2,3).
- Categoría.

En base a estos 3 inputs, el modelo es capaz de predecir el rating estimado que tendrá el lugar.